

1 题目一：基于 Telco Customer Churn 数据集的客户流失分类预测

一、数据集来源

本题使用 Telco Customer Churn 数据集。

数据集下载地址：

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn?resource=download>

二、作业要求

使用 R 语言建立机器学习分类模型，根据客户的基本信息和服务使用情况预测客户是否会流失，并尝试提取影响客户流失的重要因素。

三、作业内容

1. 下载并读取 Telco Customer Churn 数据集
2. 查看数据结构、样本数量、变量数量和变量类型，给出必要的描述性统计，并对结果给出说明；
3. 统计流失客户和未流失客户的数量及比例，判断是否存在类别不平衡问题，说明理由和处理方案；
4. 检查并处理缺失值、异常值和不合理取值；
5. 将数据进行训练集和测试集划分；
6. 对类别变量进行编码处理，对数值变量进行标准化或归一化处理，说明你的处理方式以及为什么要这样处理，对之后的训练过程和模型表现是否存在实际影响；
7. 以 Logistic 回归为基准模型，再建立 2-3 个课程中学习过的分类模型，例如：
 - KNN
 - 树模型与随机森林；
 - XGBoost；
 - 支持向量机。
8. 对训练的模型进行参数调优，简要介绍你调参的过程；
9. 使用测试集对模型进行评估，报告结果；

10. 采用课上讲过的评价指标进行评价，建议至少包括：

- Accuracy;
- Precision;
- Recall;
- F1-score;
- ROC 曲线;
- AUC;
- 混淆矩阵。

11. 给出不同模型的性能比较表，尝试解释为什么不同的模型之间性能存在差别，简单的模型表现是否会劣于复杂的模型、在测试集上性能之间的差别能否体现不同模型面对这一问题的表现有高低之分；

12. 简要介绍你发现的影响客户流失的重要变量；

13. 最终选择一个模型作为你的最终模型，展示部分预测结果。简要介绍你的模型及训练结果在客户挽留等场景下的实际应用价值；

2 题目二：基于 House Prices 数据集的房价回归预测

一、数据集来源

本题使用 House Prices - Advanced Regression Techniques 数据集。

数据集下载地址：

<https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data>

二、作业要求

使用 R 语言建立回归模型，根据房屋属性预测房屋销售价格，并比较不同回归算法的预测效果。

三、具体要求

1. 下载并读取 House Prices: Advanced Regression Techniques 数据集
2. 查看数据维度、变量类型、缺失值情况和目标变量分布，给出必要的描述性统计，并对结果给出说明；
3. 判断 SalePrice 是否存在明显偏态，并说明是否需要进行包括对数变换等方法进行处理，如果需要，说明你的处理方式；
4. 将训练数据划分为训练集和验证集，或使用交叉验证；
5. 检查并处理缺失值，对不同类型变量采用合理的填补方法，详细说明你的处理方法并给出理由；
6. 对类别变量进行编码处理，对数值变量进行标准化或归一化处理，说明你的处理方式以及为什么要这样处理，对之后的训练过程和模型表现是否存在实际影响；
7. 以多元线性回归为基准模型，另外建立建立 2-3 个课上讲过的回归模型，建议包括：
 - Ridge 或 Lasso；
 - 前馈神经网络
 - 集成学习模型。
8. 对训练的模型进行参数调优，简要介绍你调参的过程；
9. 使用测试集对模型进行评估，报告结果；
10. 采用课上讲过的评价指标进行评价，建议至少包括：

- RMSE;
 - MAE;
 - R-squared。
11. 绘制真实房价、多元线性回归与你的模型预测房价的散点图，绘制残差图，并分析模型误差；
 12. 你认为对房价影响较大的变量是什么，你的评判依据是什么，同一变量在不同模型中的表现是否有差别；
 13. 最终选择一个模型对房屋价格进行预测，并展示部分预测结果。

3 题目三：信息泄露问题

信息泄露（Data Leakage）是机器学习实践中常见且后果严重的一类错误。它指的是训练数据中包含了不应当被模型获取的测试信息和结论，导致模型在训练集上表现完美，但在部署中彻底失效。请自行查找相关资料，简要写一段对信息泄露问题的介绍。

在以上两个问题中，我们观测一下发生了信息泄露后，它们的评价指标是否发生变化？请选择至少一种泄露方式进行尝试，并进行报告。

1. **目标变量泄露：**将目标变量本身，或由目标变量直接计算得到的变量，错误地作为模型输入特征。例如在客户流失预测中将 `Churn` 或其编码结果作为自变量，在房价预测中将 `SalePrice` 或 `log(SalePrice)` 作为模型特征。
2. **数据划分前的全数据预处理泄露：**在划分训练集和测试集之前，使用全体数据进行缺失值填补、标准化、归一化、特征选择、主成分分析或类别编码等操作。这样会使测试集的信息间接参与训练过程。
3. **测试集信息泄露：**在模型调参、特征选择或模型选择过程中反复使用测试集结果，使测试集不再是独立的最终评估数据。

提交要求

1. 使用的原始数据文件
2. 完整可运行的.rmd 文件或者.r 代码
3. 包含以上问题具体解答的 HTML 或 PDF 文件