

k-means聚类算法：算法描述与iris鸢尾花实例

2312473-李一珩

2026-05-16

1. k-means 算法的数学描述

k-means 是一种基于划分的聚类方法，旨在将数据集划分为 k 个互不相交的簇，使得每个样本与其所属簇中心的距离平方和最小化。

1.1 符号定义

- 数据集： $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$ ，其中每个 $x_i \in \mathbb{R}^d$ 。
- 簇的个数： k (给定)。
- 簇的划分： $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ ，满足 $C_i \neq \emptyset$ ， $\bigcup_{i=1}^k C_i = \mathcal{X}$ ，且 $C_i \cap C_j = \emptyset$ ($i \neq j$)。
- 簇中心 (质心)： $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$ ，即簇内所有点的均值向量。

1.2 目标函数 (损失函数)

k-means 最小化簇内平方和 (Within-Cluster Sum of Squares, WCSS)：

$$\text{WCSS} = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2$$

其中 $\|\cdot\|$ 表示欧几里得距离。

1.3 迭代优化步骤

由于直接求解上述组合优化问题是 NP 难的，k-means 采用启发式迭代算法，通常称为 **Lloyd 算法**：

- 初始化**：选择 k 个样本点作为初始簇中心 $\mu_1^{(0)}, \mu_2^{(0)}, \dots, \mu_k^{(0)}$ (常用随机选取或 k-means++)。
- 分配 (Assignment step)**：将每个样本点分配到最近的簇中心：

$$C_j^{(t)} = \left\{ x_i : \|x_i - \mu_j^{(t)}\|^2 \leq \|x_i - \mu_l^{(t)}\|^2 \forall l \in \{1, \dots, k\} \right\}$$

- 更新 (Update step)**：重新计算每个簇的质心：

$$\mu_j^{(t+1)} = \frac{1}{|C_j^{(t)}|} \sum_{x \in C_j^{(t)}} x$$

- 收敛判断**：重复步骤 2 和 3，直到簇中心不再变化 (或变化小于阈值)，或达到最大迭代次数。

1.4 算法性质

- 收敛性**：每次迭代 WCSS 严格下降 (或保持不变)，且存在下界，因此算法必然收敛 (但不一定收敛到全局最优)。

- **时间复杂度**： $O(I \cdot k \cdot n \cdot d)$ ，其中 I 为迭代次数，通常较小。
- **局限性**：
 - 需要预先指定 k 。
 - 对初始中心敏感，易陷入局部最优。
 - 对噪声和异常值敏感（因为使用平方距离）。
 - 假设簇是凸的、大小相近、球形分布。

2. k-means 实例——基于R自带的iris鸢尾花数据集

使用 R 内置的 `iris` 鸢尾花数据集

去除物种标签，仅用四个数值特征，我们将展示：

- 如何确定最佳 k （肘部法则）；
- 执行 k-means 聚类；
- 可视化聚类结果（降维后展示）。

2.1 加载数据与预处理

```
data(iris)
# 只使用数值特征
iris_features <- iris[, 1:4]
head(iris_features)
```

```
##      Sepal.Length Sepal.Width Petal.Length Petal.Width
## 1           5.1         3.5         1.4         0.2
## 2           4.9         3.0         1.4         0.2
## 3           4.7         3.2         1.3         0.2
## 4           4.6         3.1         1.5         0.2
## 5           5.0         3.6         1.4         0.2
## 6           5.4         3.9         1.7         0.4
```

2.2 确定簇的数量：肘部法则


计算不同 k （2~10）对应的 WCSS，选择“肘部”位置。

```
set.seed(123)
wcss <- sapply(2:10, function(k) {
  kmeans(iris_features, centers = k, nstart = 25)$tot.withinss
})

elbow_df <- data.frame(k = 2:10, wcss = wcss)

ggplot(elbow_df, aes(x = k, y = wcss)) +
  geom_line(color = "steelblue", size = 1) +
  geom_point(size = 2) +
  labs(title = "肘部法则确定最佳 k 值", x = "簇数 k", y = "WCSS") +
  theme_minimal()
```

肘部法则确定最佳 k 值



图中显示在 $k = 3$ 处出现明显“肘点”，与 iris 真实类别数一致，因此选择 $k = 3$ 。

2.3 执行 k-means 聚类

```
set.seed(123)
km_result <- kmeans(iris_features, centers = 3, nstart = 25)
# 查看聚类结果摘要
table(km_result$cluster)
```

```
##
##  1  2  3
## 50 62 38
```

2.4 可视化聚类结果


由于原始数据是四维的，我们使用 PCA 降维到二维平面来展示聚类效果。

```
# 执行 PCA
pca <- prcomp(iris_features, scale. = TRUE)
pca_df <- as.data.frame(pca$x[, 1:2])
pca_df$cluster <- as.factor(km_result$cluster)
pca_df$species <- iris$Species # 真实标签（仅用于对照）

# 绘制聚类结果（颜色表示算法分配的簇）
ggplot(pca_df, aes(x = PC1, y = PC2, color = cluster)) +
  geom_point(size = 2, alpha = 0.7) +
  stat_ellipse(aes(fill = cluster), type = "norm", alpha = 0.2, geom = "polygon") +
  labs(title = "k-means 聚类结果 (k=3)",
       subtitle = "基于 PCA 降维，椭圆表示 95% 置信区间") +
  theme_minimal()
```

k-means 聚类结果 (k=3)


基于 PCA 降维，椭圆表示 95% 置信区间



为验证聚类效果，可以对照真实物种标签：

```
ggplot(pca_df, aes(x = PC1, y = PC2, color = species)) +
  geom_point(size = 2, alpha = 0.7) +
  labs(title = "真实物种标签（对照）") +
  theme_minimal()
```

真实物种标签（对照）



可以看到，k-means 聚类结果与真实类别高度吻合，仅有少量样本可能被混淆。

2.5 输出簇中心信息

```
centers <- km_result$centers
colnames(centers) <- names(iris_features)
knitr::kable(centers, caption = "三个簇的中心（原始特征尺度）")
```

三个簇的中心（原始特征尺度）

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
5.006000	3.428000	1.462000	0.246000
5.901613	2.748387	4.393548	1.433871
6.850000	3.073684	5.742105	2.071053

3. 总结

- **数学描述：**k-means 通过最小化簇内平方和来划分数据，迭代执行“分配-更新”两步，是一种简单高效的聚类算法。
- **实例演示：**对鸢尾花数据集，肘部法则确定最佳簇数 $k = 3$ ，聚类结果与真实类别高度一致，验证了算法的有效性。

...